

논증 오류 특화 적대 평가와 목적-주석 기반 실패 재활용을 결합한 다측면 LLM 심사 하네스

A Multi-Aspect LLM Review Harness for Adversarial Argument-Error Evaluation and Purpose-Annotated Failure Recycling

문서 성격	시스템 설계 공개서 / 코드 스냅샷 기술문서
저자	최현서 (Hyunseo Choi)
ORCID	0009-0002-7757-0274
문서 버전	Design Disclosure 1.1
소프트웨어 버전	analogy-review-harness 0.15.1
공개 기준일	2026-06-23 (Asia/Seoul)
DOI	10.5281/zenodo.20814616 (reserved)
라이선스	Code: Apache-2.0 / Documents: CC BY 4.0

공개 범위

이 문서는 구현된 코드와 설계 원리를 낱자가 있는 공개 기록으로 고정한다. 동종 평가법보다 더 나은 평가 성능을 보인다는 주장은 아직 연구가설이며, 후속 대규모 실험을 통과하기 전에는 성능 결론으로 간주하지 않는다.

동봉 코드 스냅샷 analogy-review-harness-v0.15.1-disclosure.zip

SHA-256 3458E06359C2585ABB40234D8B2F7E82D3FCC4B8D78E5F08CE3F9A38176EB75A

Status: public technical disclosure; not peer reviewed.

01 문서 목적과 주장 경계

What is fixed by this disclosure, and what remains a hypothesis

본 공개서는 유추생성 다측면심사 하네스의 구현 구조, 사건 중심 검증 방식, 제한된 적대 테스트케이스 생성, 실패 재활용 경로를 재현 가능한 형태로 기술한다. 공개 시점의 코드는 연구용 프로토타입이며, 논문에서 주장할 비교 성능 향상은 별도의 사전등록 실험으로 검증해야 한다.

검증된 현재 사실

- Python 패키지 버전은 **0.15.1**이며, 생성 - 다측면 심사 - Gate - 재심 - Library - Ratchet - 최종 제출 경로가 코드로 존재한다.
- 공통 Event Contract Validator(사건 계약 검증기)가 Gate, Library, Case, Ratchet, Snapshot의 출처와 상태 전이를 재검증한다.
- 제한된 Argument-Defect Test-Case Generator(논증 결함 테스트케이스 생성기)가 후보 문장과 Hidden Oracle(숨은 정답)을 분리하고, 시스템 공격·권한 우회 등은 OUT_OF_SCOPE으로 거부한다.
- 2026-06-23 재실행한 회귀검증은 **133개 중 133개 통과**다. Probe 정답 계약은 결함문항의 탐지와 정상문항의 clear 판정을 구분한다.

아직 입증되지 않은 연구가설

- 본 시스템이 Single LLM-as-Judge, PoLL, Self-Refine, Reflexion, N-Critics, Multi-Agent Debate보다 논리 오류 탐지와 재발 방지에서 더 나은 평가 성능을 보인다는 가설.
- Purpose-Annotated Library(목적·주석 라이브러리)가 분야를 가로지르는 유추 재사용을 안정적으로 향상한다는 가설.
- 모델 계통 다양성, 사건 계약, 사람 Gate, 실패 재활용 중 어느 구성요소가 개선을 만드는지에 대한 인과적 기여도.

법적 표현 주의

GitHub와 Zenodo 공개는 날짜가 있는 공개 증거와 Defensive Publication(방어적 공개) 역할을 할 수 있지만, 특허 출원이나 모든 국가에서의 법적 우선권을 대신하지 않는다. 특허 가능성을 남길 필요가 있다면 공개 전에 변리사 또는 특허변호사와 확인해야 한다.

02 권고 제목과 연구 포지셔닝

권고 공개 제목

Korean

논증 오류 특화 적대 평가와 목적-주석 기반 실패 재활용을 결합한 다측면 LLM 심사 하네스: 시스템 설계 및 선행 공개

English

A Multi-Aspect LLM Review Harness for Adversarial Argument-Error Evaluation and Purpose-Annotated Failure Recycling: System Design and Prior Disclosure

제목을 이렇게 바꾼 이유

원안	권고 표현	근거
논리적 오류	논증 오류(Argument Error)	형식논리뿐 아니라 숨은 전제, 범위 과장, 거짓 유추, 필요·충분조건 혼동까지 포함하는 실제 구현 범위와 더 잘 맞는다.
유추 메커니즘	목적-주석 기반 실패 재활용	현재 구현은 목적·작동조건·실패조건을 붙여 검색하는 Library다. 자동 유추 생성 능력까지 입증됐다고 쓰면 과장이다.
재활용 시스템	다측면 LLM 심사 하네스	무엇을 재활용하는지와 평가 시스템의 정체를 제목에서 바로 드러낸다.

후속 실증 논문 제목 후보

Recycling Failed Reasoning: Multi-Aspect Adversarial Evaluation for Logical-Error Detection in LLM Systems

이 제목은 비교 실험이 실제로 성능 향상을 보였을 때 사용한다. 공개 설계서와 실증 논문의 제목을 분리하면, 선행 공개와 성능 주장의 증거 수준을 혼동하지 않는다.

프레임 외 대안 검토

특허가 아니라 학술적 기여를 최우선으로 잡는다면, Zenodo 공개와 동시에 짧은 Technical Report(기술보고서) preprint를 올리는 경로가 검색성과 인용성에서 더 강하다. 현재 회귀검증은 통과했지만 비교 실험은 미완성이므로, Technical Report는 설계 공개와 성능 검증 결과를 분리해 버전을 고정하는 편이 낫다.

03 문제 정의와 핵심 연구 질문

LLM 출력 평가는 단일 판정자의 편향, 같은 모델 계통의 공통 사각지대, 자기수정의 자기확증, 토론 에이전트 간 수렴 착시를 가질 수 있다. 본 시스템은 하나의 점수로 모든 품질을 압축하지 않고, 서로 다른 관할을 가진 심사관이 사건을 남기고 사람이 Gate에서 명시적으로 처리하도록 설계한다.

핵심 연구 질문


ID	질문
RQ1	다측면 독립 심사가 단일 LLM-as-Judge보다 논증 오류 탐지율과 오류 위치 특정 정확도를 높이는가?
RQ2	다양한 모델 계통으로 구성된 Panel(패널)이 동일 계통 다중 심사보다 공통 사각지대를 줄이는가?
RQ3	확정된 실패 사건을 Block-rule과 Purpose-Annotated Library로 되먹일 때 같은 오류의 재발이 감소하는가?
RQ4	사건 계약 검증과 사람 Gate가 추가 비용 대비 출처 위조·상태 건너뛰기·오류 피드백 오염을 유의미하게 줄이는가?
RQ5	성능 개선이 단순 계산량 증가가 아니라 구조적 구성요소에서 오는가?

설계 원칙

- **사전 보증을 사후 도태로 전환:** 완벽한 점수표를 먼저 만들기보다, 사건을 기록하고 잘못된 후보를 되돌리며 규칙을 강화한다.
- **사람을 영점으로 사용:** Gate 임계값 60/75/85를 자동화하지 않고, 충돌·불확실성·수정 요구를 사람이 명시적으로 결정한다.
- **미확정 사건 격리:** 필터를 빠져나온 의심 사례는 바로 학습 신호가 되지 않으며, confirmed 상태와 별도 승인 전까지 shadow로 남는다.
- **비차단 보강:** OLMo 2 영어 감사는 한국어 승인 본문을 변경하거나 Gate를 뒤집지 않고 별도 Advisory(보강 보고)만 만든다.

04 시스템 아키텍처

Pipe-first implementation with local flow checks



배관 비유로 보면 각 상자는 처리 장치, 화살표는 사건과 후보가 이동하는 경로다. 각 구간에서 소량의 물을 흘려 계약과 상태 전이를 확인하고, 전체 배관 완성 후 End-to-End(종단간) 운영 연기를 수행하는 방식이다.

주요 구성요소

구성요소	역할
Generator	과제와 기존 Block-rule을 받아 후보 주장을 생성한다.
Reviewer Registry	논리·코드·수학·물리·범위·사각지대 관할을 등록 순서대로 실행한다.
Orchestrator	관할 공백, 같은 측면의 충돌, 종속핵심 차단을 집계한다.
Event Contract Validator	사건 ID, 후보 ID, 출처 사건, 이전 상태, 허용 전이를 조회 때마다 재검증한다.
Gate 1-3	사람의 pass/revise/reject/accept 결정을 기록하는 상태기계다.
Case + Feedback	의심 사건을 confirmed/dismissed로 확정하고, 별도 승인된 사례만 다음 생성에 주입한다.
Library	버려진 결과의 쓸 만한 부분을 목적·전제·작동조건·실패조건과 함께 보존한다.
Ratchet + Snapshot	측면별 Champion(현재 우승안)을 비교하고, 개선이 없을 때 사람 승인으로 종료 스냅샷을 만든다.

05 다측면 심사와 사건 계약

심사 결과는 단일 총점이 아니라 verdict, defect_found, confidence, defect_type, defect_location, revision_instruction 등 구조화 필드로 기록된다. 여기서 confidence는 판정자의 자신감이지 10개 품질측을 합산한 절대 점수가 아니다.

Review Contract(심사 계약)

판정	핵심 조건	의미
reject / revise	defect_found=true 필수	오류 유형과 위치 필수. revise에는 수정 지시도 필수.
pass_to_next_gate	defect_found=false 필수	오류 세부정보를 함께 기록하면 계약 위반.
needs_human_review	true 또는 false	모호성 자체를 보존하며 억지로 오류 존재 여부를 확정하지 않는다.
salvageable_part	reject/revise에서만 허용	기각된 결과의 부분 재사용 후보. 즉시 검색 가능 상태가 아니다.

사건 계약이 막는 오류


- 다른 과제나 다른 후보의 심사 결과를 현재 Gate에 붙이는 provenance mismatch(출처 불일치).
- Gate 1에서 Gate 3 완료로 건너뛰거나, 재심 결과가 없는데 최종 승인하는 불법 상태 전이.
- 저장된 JSONL 값을 직접 변조해 clear 또는 accepted 상태로 위조하는 시도.
- Library 부분이 가리키는 source_event_id와 source_candidate_id의 불일치.

설계 선택

Append-only log(추가 전용 로그)는 기록을 남기지만 그 자체로 진실을 보장하지 않는다. 따라서 조회 시 원본 사건과 상태 전이를 다시 재생해 검증한다. 일상 비유로는 영수증이 존재하는지만 보는 것이 아니라, 품목·금액·결제 시점이 실제 주문과 맞는지도 다시 대조하는 방식이다.

06 제한된 적대 평가와 Hidden Oracle

퀘변 생성기는 시스템 공격자가 아니라 심사 성능 검증용 Test-Case Generator(테스트케이스 생성기)다. 생성 범위는 주장·논증·유추 구조 내부의 오류로 제한되며, 각 샘플은 삽입 오류 유형, 위치, 오류 이유, 심사 포인트, 기대 판정을 함께 가진다.



안전 및 과학적 경계

구분	내용
허용	순환논증, 숨은 전제, 상관-인과 혼동, 범위 과장, 거짓 유추, 양화사 오류, 정의역 누락, 필요·충분조건 혼동 등
금지	외부 시스템 공격, 권한 우회, 도구 실행, 메모리 변조, 사용자 조작, 보안 취약점 악용, 사회공학적 설득문
정답 분리	후보 본문은 reviewer에게 전달하지만 Hidden Oracle은 로그에만 남겨 label leakage(정답 누설)를 방지
목적함수	심사관을 속이는 것이 아니라 특정 오류를 정확히 탐지하고 위치를 특정하는지 평가

현재 probe 구성

현재 코드에는 총 **20개** 기본 probe가 있다. 기존 8개 결함 사례, 6개 정상 통제 사례, 6개 추가 결함 사례로 구성된다. Mock backend와 CLI는 결함 탐지와 정상 clear를 구분하는 정답 계약으로 갱신됐으며 관련 회귀검증을 포함한 133개 테스트가 모두 통과한다.

07 실패 재활용과 유추의 실제 구현 범위

이 시스템의 재활용은 두 경로다. 첫째, 확정된 오류를 다음 생성에서 피해야 할 Block-rule로 주입한다. 둘째, 기각된 답의 부분적 장점을 목적과 조건을 붙여 Library에 저장한다. 둘 다 사람이 확인한 사건만 사용해 오염된 피드백의 자기증폭을 막는다.

경로	입력	승인 조건	출력
오류 재발 방지	filter escape 또는 재심 overturn 사건	confirmed + readiness 승인 + case별 활성화 승인	다음 생성 프롬프트의 Block-rule
부분 재사용	reject/revise의 salvageable_part	전제·검증맥락·works_when-fails_when-purpose + 목적 승인	목적과 조건이 맞을 때 검색

Purpose-Annotated Analogy(목적-주석 유추)

Library는 내용의 표면적 유사성보다 '왜 이 부분을 쓰는가'를 먼저 맞춘다. 예를 들어 서로 다른 분야의 문장이라도 목적이 '숨은 전제 노출'이고 작동조건이 같으면 재사용 후보가 된다. 이는 유추를 위한 구조적 발판이지만, 현재 코드는 자동으로 먼 분야의 유추를 생성하거나 그 품질을 보증하지 않는다.

주장 경계

현재 입증 가능한 표현은 '목적과 작동조건을 붙인 재사용 저장소가 구현됐다'이다. '유추 메커니즘이 일반적 추론 성능을 높인다'는 표현은 후속 실험에서 목적-주석 Library를 제거한 ablation(구성요소 제거 실험)과 비교한 뒤에만 사용한다.

08 현재 구현 상태와 공개 시점의 결함

상태	항목	공개 시점 설명
구현	Event Contract Validator	Gate-Library-Case-Ratchet-Snapshot의 출처·상태·연결 검증
구현	Gate state machine	3단계 수동 판정, 수정 재진입, 재심 연결, 최종 승인
구현	제한 적대 생성기	Hidden Oracle 분리, 논증 오류 한정, OUT_OF_SCOPE 차단
구현	실패 재활용	확정 Block-rule 주입, 목적-주석 Library intake/승인/검색
구현	Ratchet/Termination	측면별 Champion, 종료 적격성, 불변 Snapshot
구현	OLMo 2 보강 감사	영어 감사 후 한국어 Advisory, Gate 비차단
부분	로컬 7+1 모델 배치	confirmed-local 프로필과 실기기 시험 기록은 있으나, 동일 벤치마크 종합 검증은 미완료
미구현	Part III 10축 0-100 Rubric	goal_relevance 등 자동 점수와 60/75/85 threshold 판정 없음
미입증	비교 성능 향상	6개 기준선 대비 수백 건 실험과 통계 검증 전
미입증	일반 유추 향상	자동 cross-domain analogy와 기여도 실험 전

회귀검증 상태

133 / 133 PASS

수리 완료: 정상 통제문항은 오류 미탐지만으로 합격하지 않고, 필수 관찰 심사가 수행된 뒤 batch status가 clear일 때만 정답으로 기록한다.

실모델 20문항: 결함 14/14 탐지, 정상 4/6 무결함 판정, 엄격 정답 17/20. clean-code와 clean-physics는 거짓 양성, clean-scope는 empty_aspect 미판정이다.

가속 상태

현재 문서화된 실행 경로는 Intel Arc 140V에서 Ollama의 Vulkan backend를 사용한 iGPU 적재다. IPEX-LLM 가속을 현재 구현 사실로 표기하지 않는다. 모델별 '실행됨'과 '연구 벤치마크에서 검증됨'도 구분한다.

09 로컬 모델 역할 배치

Working roster, not a performance claim

자리	모델	관할	상태
주장 생성	qwen3.5:9b	후보 생성	실행 확인
코드 심사	gemma4:12b	코드 결함	구조화 출력·iGPU 확인
논리 심사	phi4-reasoning:14b	논증 결함	미끼 적발 확인
수학 심사	gpt-oss:20b	수학 오류	fallback 포함 실행 확인
물리 심사	llama3.1:8b	물리·차원	조건부 배치; 설명 일관성 주의
범위 심사	ministral-3:14b	범위 과장	iGPU·적합성 시험 확인
사각지대 심사	qwen3.5:9b	개인정보·권한 등	GLM 대체 운영안
비차단 후속 감사	olmo2:13b	영어 정규화본 재감사	Gate 밖 Advisory
번역 보조	qwen3.5:9b	감사 경계 번역	한국어 보고서 생성
외부 재심	Claude Opus 계열	사람이 전달하는 2차 의견	자동 backend 아님

독립성 주의

생성기와 사각지대 심사관이 같은 qwen3.5:9b 계통이므로 완전한 계통 독립성은 아니다. 운영상 자원 제약을 반영한 배치이며, 논문에서는 '역할 수'와 '모델 계통 다양성'을 별도 변수로 다뤄야 한다.

재쟁점화 조건

동일 계통 생성기와 사각지대 심사관에서 반복 누락이 관찰되면, OLMo 2 또는 별도 계통 모델을 Gate 심사관으로 승격하는 실험군을 추가한다. 그 전에는 현재 배치의 메모리·속도 이점이 더 크므로 운영안을 유지한다.

10 비교 실험 설계

비교 성능 향상은 '우리 시스템이 더 복잡하다'가 아니라, 같은 자원과 같은 테스트에서 더 많은 실제 오류를 잡고 정상 문장을 덜 기각하며 확정 실패의 재발을 줄이는지로 판단한다.

ID	비교군	핵심 구조
B0	Single LLM-as-Judge	단일 모델 1회 판정
B1	PoLL	다양한 모델 패널의 집계 판정
B2	Self-Refine	동일 모델의 피드백-수정 반복
B3	Reflexion	언어적 피드백을 에피소드 메모리로 재사용
B4	N-Critics	다수 외부 비평을 생성 모델이 통합
B5	Multi-Agent Debate	복수 에이전트 토론 후 판정
H	본 하네스	관할 분리 + 사건 계약 + 사람 Gate + 확정 실패 재활용

공정성 통제

- 동일한 원문, 동일한 정답 라벨, 동일한 언어 분포, 동일한 도구 접근권한을 사용한다.
- Primary comparison(주 비교)은 총 토큰 예산 또는 총 추론비용을 맞춘다. 보조 비교에서 각 방법의 기본 권장 설정을 별도로 보고한다.
- 판정 순서는 무작위화하고 시스템 이름을 가린다. 정답 라벨은 평가자에게 숨긴다.
- 오류 유형과 난이도별 층화 결과를 보고해 평균값이 특정 쉬운 유형에 끌려가지 않게 한다.
- 구성요소 제거 실험: 모델 다양성, Event Contract, 사람 Gate, Block-rule, Purpose Library를 각각 제거한다.

11 데이터셋과 평가 지표

계획값 - 사전등록 전 변경 가능

권고 시작 규모는 **600건**이다: 결함 사례 400건(8개 오류군 x 50) + 정상 통제 200건. 한국어와 영어를 증화해 번역 성능과 논리 심사 성능을 분리한다. 이 숫자는 현재 성능결론이 아니라 실험 설계의 출발점이다.

Primary Metrics(주요 지표)

지표	정의	역할
오류 탐지 Recall	실제 결함 사례 중 결함 사건을 올바르게 낸 비율	핵심
정상 사례 False Rejection	정상 통제를 reject/revise한 비율	핵심
오류 유형 정확도	삽입된 오류 유형과 판정 유형의 일치	핵심
오류 위치 정확도	문장-전제-수식 위치를 맞춘 정도	핵심
재발률	확정 피드백 후 같은 오류가 다시 발생한 비율	핵심
오염률	잘못 확정된 사건이 Block-rule/Library에 들어간 비율	안전
비용-지연	토큰, wall-clock, 에너지 또는 메모리	보조

통계 계획

- 같은 사례를 여러 방법이 판정하므로 paired design(대응 설계)을 사용한다.
- 이진 성공률 차이는 McNemar 검정과 paired bootstrap 95% confidence interval(대응 부트스트랩 신뢰구간)을 함께 보고한다.
- 오류 유형별 다중 비교는 Holm 보정으로 과잉 유의성을 통제한다.
- 효과크기와 신뢰구간을 1차로 보고하고, p-value만으로 더 나은 성능을 선언하지 않는다.
- 실험 전 가설, 제외 규칙, primary metric, 중단 조건을 사전등록한다.

유도리 게이트와 측정의 경계

운영 중에는 사건 탐지만으로 충분하지만, 논문에서 비교 성능 향상을 주장하려면 비율과 신뢰구간이 종속핵심이다. 따라서 dashboard를 상시 운영 장치로 만들 필요는 없고, 실험 분석 스크립트에서 사후 집계하면 된다.

12 위험요인, 반증조건, 연구 중단 기준

위험	문제	완화
모델 계통 공통편향	생성기와 일부 심사관의 동일 계통	계통 다양성 ablation 및 독립 모델 교체군
정답 누설	prompt 또는 로그에서 Hidden Oracle 노출	후보/정답 저장 분리, 실행 추적 감사
번역 혼입	영어 감사 성능과 번역 품질 혼동	원문·영문 정규화본·한국어 Advisory를 별도 평가
사람 Gate 편향	사용자가 시스템 정체를 알고 판정	블라인드 외부 평가자와 일치도 보고
벤치마크 과적합	고정 probe 반복으로 규칙 암기	비공개 holdout 및 새 오류 조합
계산량 우위	더 많은 모델 호출이 성능 차이 원인	토큰/비용 일치 비교
정상 통제 오판	실모델 20문항에서 거짓 양성 2건·관할 미진입 1건	후속 prompt·관할 개선과 비공개 holdout 재시험

Kill-switch(결론 무효 조건)

- **비용을 맞춘 비교**에서 본 하네스의 오류 탐지 Recall 항상 신뢰구간이 0을 포함하고, 정상 사례 오기각이 더 높다면 성능 향상 결론을 폐기한다.
- Purpose Library 제거군과 전체 시스템 간 재발률 차이가 재현되지 않으면 '유추 기반 재활용이 성능을 높인다'는 주장을 폐기한다.
- Hidden Oracle 또는 사례 라벨이 심사 입력에 누설된 흔적이 발견되면 해당 실험 전체를 무효 처리한다.
- 외부 블라인드 평가자의 gold label 일치도가 기준 이하라면 모델 비교 전에 데이터셋 라벨부터 재구축한다.

현재 결론

이 설계는 비교 실험을 수행할 수 있는 구조적 기반은 제공한다. 그러나 2026-06-23 현재 동종 방법 대비 더 나은 평가 성능은 확인되지 않았다. 후속 실험이 위 반증조건을 통과할 때만 성능 결론을 낸다.

13 Zenodo 공개 패키지와 재현 절차

권고 공개 묶음

항목	파일	목적
설계 PDF	Analogy_Review_Harness_Zenodo_Design_Disclosure_v1.1.pdf	시스템·주장 경계·실험 계획
코드 ZIP	analogy-review-harness-v0.15.1-disclosure.zip	공개 시점 소스 스냅샷
README	README.md	설치·실행·현재 한계
인용 정보	CITATION.cff	저자, ORCID, 제목, 버전, DOI
Zenodo 메타데이터	.zenodo.json	creators, keywords, related identifiers
코드 라이선스	LICENSE	Apache License 2.0
문서 라이선스	LICENSE-DOCUMENTATION.md	CC BY 4.0
변경 기록	PATCH_NOTES.md	버전별 변경
무결성	SHA256SUMS.txt	파일 변조 확인

권고 게시 순서

1. 133/133 회귀검증과 compileall 통과를 재확인한다.
2. Git 저장소를 초기화하고 공개에 불필요한 로그·비밀·개인 경로를 제거한다.
3. LICENSE, CITATION.cff, .zenodo.json, SHA256SUMS.txt를 추가한다.
4. GitHub 저장소 <https://github.com/chlgustj0512/LLM-Review-Harness-With-Recycling>에 공개 파일을 올리고 release tag v0.15.1-disclosure를 만든다.
5. 예약 DOI 10.5281/zenodo.20814616가 표지·CITATION.cff·README에 일치하는지 확인한다.
6. Zenodo Licenses 필드에 Apache-2.0과 CC-BY-4.0을 모두 추가한다.
7. Zenodo Resource type은 Software를 기본으로 하고, 이 PDF를 부가 기술문서로 함께 올린다.

중요

Zenodo 게시 후 파일을 임의로 바꾸지 말고 새 버전으로 발행한다. 버전 DOI는 해당 스냅샷을 가리키고, Concept DOI는 모든 버전을 묶는 식별자로 사용한다.

14 공개 메타데이터 초안

필드	권고값
Resource type	Software
Title	A Multi-Aspect LLM Review Harness for Adversarial Argument-Error Evaluation and Purpose-Annotated Failure Recycling
Creator	Choi, Hyunseo
ORCID	https://orcid.org/0009-0002-7757-0274
DOI	10.5281/zenodo.20814616
Version	0.15.1
Publication date	실제 Zenodo 게시일
Language	Korean; English abstract included
Keywords	LLM-as-a-judge; logical error; adversarial evaluation; multi-agent review; failure recycling; provenance; analogy
Related identifier	https://github.com/chlgustj0512/LLM-Review-Harness-With-Recycling
Licenses	Apache-2.0 (software); CC-BY-4.0 (documents/PDF)

영문 초록 초안

Abstract

This technical disclosure presents a multi-aspect LLM review harness for detecting argument-level errors, preserving provenance through event-contract validation, and recycling confirmed failures through block rules and a purpose-annotated library. The system separates candidate text from hidden test oracles, restricts adversarial generation to labeled argument defects, uses explicit human gate decisions, and supports a non-blocking cross-lineage post-review audit. The current software snapshot implements the end-to-end event plumbing but does not yet establish better evaluation performance than existing LLM evaluation and refinement methods. A controlled comparative study against single LLM-as-judge, PoLL, Self-Refine, Reflexion, N-Critics, and Multi-Agent Debate is proposed.

권고 인용 형식

Choi, Hyunseo. (2026). A Multi-Aspect LLM Review Harness for Adversarial Argument-Error Evaluation and Purpose-Annotated Failure Recycling (Version 0.15.1) [Computer software]. Zenodo.
<https://doi.org/10.5281/zenodo.20814616>

15 출처와 증거 등급

- [1] T1 Zenodo, Enable a repository. <https://help.zenodo.org/docs/github/enable-repository/>
- [2] T1 Zenodo, Create new upload. <https://help.zenodo.org/docs/deposit/create-new-upload/>
- [3] T1 Zenodo, Describe software and metadata files. <https://help.zenodo.org/docs/github/describe-software/>
- [4] T1 Zenodo, Licenses and rights, including mixed-license uploads. <https://help.zenodo.org/docs/deposit/describe-records/licenses/>
- [5] T1 Apache Software Foundation, Apache License 2.0. <https://www.apache.org/licenses/LICENSE-2.0>
- [6] T1 Creative Commons, Attribution 4.0 International. <https://creativecommons.org/licenses/by/4.0/>
- [7] T1 GitHub Docs, About CITATION files.
<https://docs.github.com/en/repositories/managing-your-repositorys-settings-and-features/customizing-your-repository/about-citation-files>
- [8] T1 WIPO, Frequently Asked Questions: Patents. https://www.wipo.int/en/web/patents/faq_patents
- [9] T1 Zheng et al. (2023). Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena. arXiv:2306.05685. <https://doi.org/10.48550/arXiv.2306.05685>
- [10] T1 Verga et al. (2024). Replacing Judges with Juries: Evaluating LLM Generations with a Panel of Diverse Models. arXiv:2404.18796.
<https://arxiv.org/abs/2404.18796>
- [11] T1 Madaan et al. (2023). Self-Refine: Iterative Refinement with Self-Feedback. arXiv:2303.17651. <https://arxiv.org/abs/2303.17651>
- [12] T1 Shinn et al. (2023). Reflexion: Language Agents with Verbal Reinforcement Learning. arXiv:2303.11366. <https://arxiv.org/abs/2303.11366>
- [13] T1 Mousavi et al. (2023). N-Critics: Self-Refinement of Large Language Models with Ensemble of Critics. arXiv:2310.18679.
<https://arxiv.org/abs/2310.18679>
- [14] T1 Liang et al. (2023). Encouraging Divergent Thinking in Large Language Models through Multi-Agent Debate. arXiv:2305.19118.
<https://arxiv.org/abs/2305.19118>
- [15] T1 ORCID public record, 0009-0002-7757-0274. <https://orcid.org/0009-0002-7757-0274>
- [16] 프로젝트 1차 자료 analogy-review-harness source tree, version 0.15.1; local regression run on 2026-06-23; snapshot SHA-256 recorded on cover.

증거 평가

현재 구현 상태: 신뢰도 98% - 데이터밀도 높음 / 최신성 2026-06-23 / 논리일관성 높음. 코드와 테스트 직접 확인.

Zenodo-GitHub 절차: 신뢰도 95% - 공식 문서 / 최신성 확인 / 절차 일관성 높음.

비교 성능 향상: 확인 불가 - 기준선 대조 실험 데이터 없음. 본 문서는 가설과 검증계획만 제시.

End of design disclosure.